


■線形の場合&未観測潜在変数あり（DDS 2 既存、QuickPredict1.5 予定機能(rcd)）



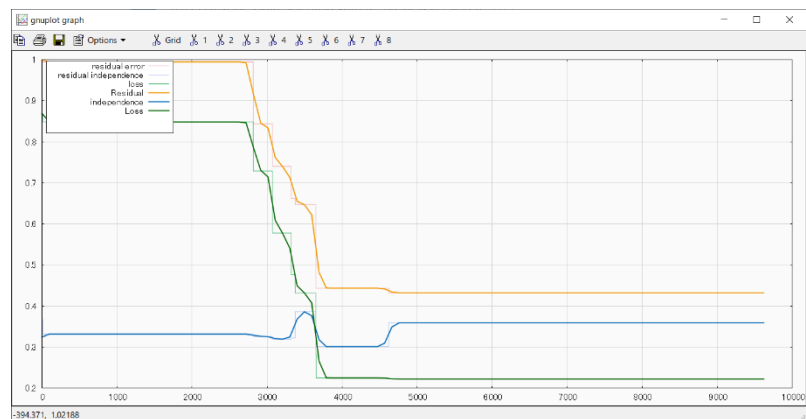

$$x_1 = e_1$$

$$x_2 = -0.7x_1 + 1.2f_1 + e_2$$

$$x_3 = 0.5x_1 + f_2 + e_3$$

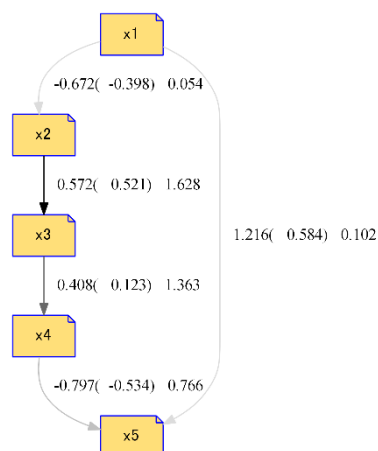
$$x_4 = -0.5x_3 + 0.8f_1 + 1.2f_2 + e_4$$

$$x_5 = 1.2x_1 - 0.8x_4 + e_5$$



■非線形を仮定した場合&未観測潜在変数あり（未踏の機能）

※データは線形のままなので結果は同じになるはずで因果効果の値も同じになるはず。



因果効果の値もほぼ同じ。

■データも非線形で未観測潜在変数はない場合（未踏の機能）

$$x_3 = e_3$$

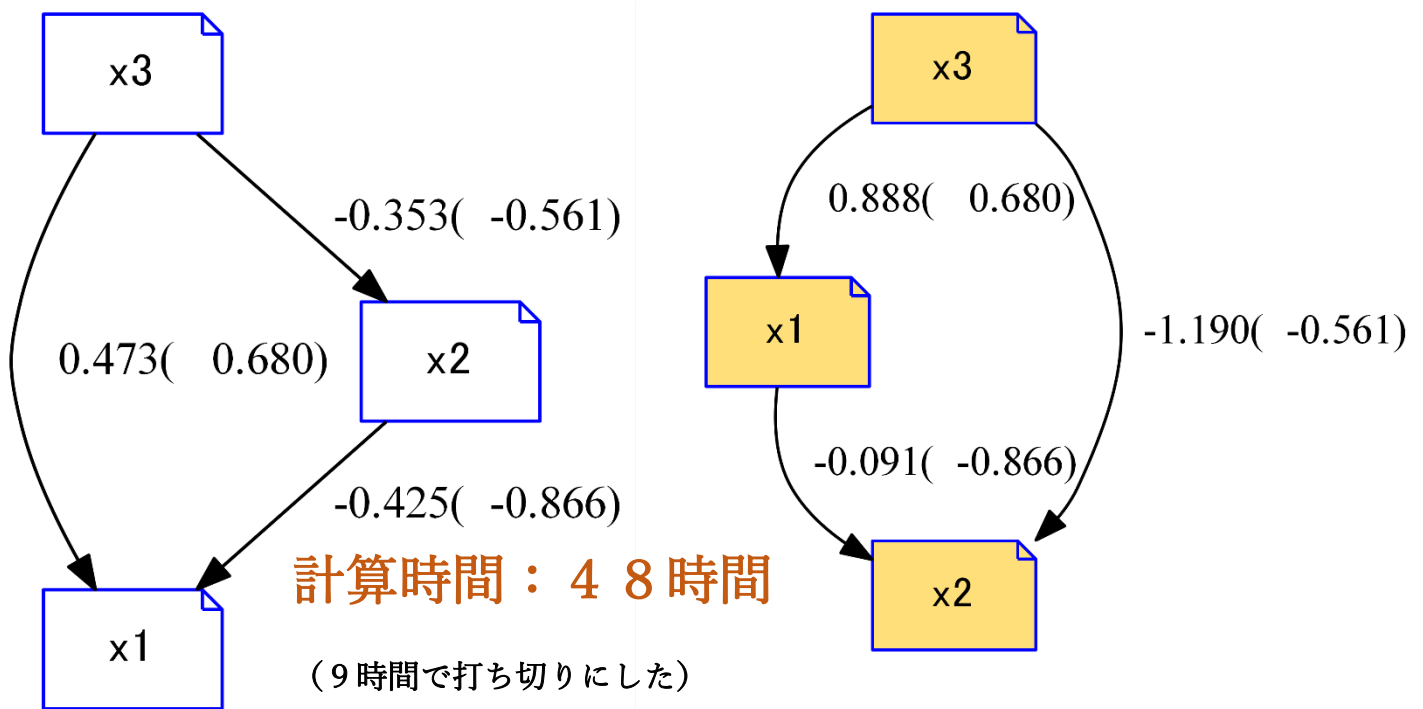
$$x_1 = 1.4x_1^4 + e_1$$

$$x_2 = -0.8x_1^2 + 0.5x_3^5 + e_2$$

LiNGAM は $x_1 \rightarrow x_2$ が逆になった。

※非線形なので LiNGAM では正しい因果構造を推論できない。

一方、非線形版（まだ実証検証中）では正しい因果構造を推論できている。



課題

因果効果の値がめちゃくちゃになる。これは当然の結果なので仕組みには問題ないが因果効果の強さを定量化できない。

※線形データではないので「何倍」とかまったく言えなくなる。。。

■今回試行したモデルの説明

まず、先行研究として滋賀大・清水先生の最近の論文があります。

RCD (Repetitive causal discovery of linear non-Gaussian acyclic models with latent confounders)

<https://arxiv.org/pdf/2001.04197.pdf>

RCD は未観測の潜在変数があっても良い LiNGAM の拡張で変数間の関係は線形を仮定しています。近年の進展ではやはり滋賀大・清水先生の最近の論文で CAM-UV (Discovery of Causal Additive Models in the Presence of Unobserved Variables) があります。RCD の非線形版に相当するモデルを提案しています。 <https://arxiv.org/pdf/2106.02234.pdf>

2 MODEL DEFINITION

Let $X = \{x_i\}$ denote the set of observed variables, $Y = \{y_i\}$ the set of unobserved variables, and $V = \{v_i\}$ the set of all the observed and unobserved variables ($V = X \cup Y$). We assume the data generation model is formulated as

$$v_i = z_i + w_i + n_i, \quad z_i = \sum_{x_j \in P_i} f_j^{(i)}(x_j), \quad w_i = \sum_{y_k \in Q_i} f_k^{(i)}(y_k) \quad (1)$$

観測データ x と未観測データ y と外生因子（ノイズ）の足し算（線形）だけを仮定
外生因子（ノイズ）の足し算（線形）を仮定するというのは普通（additive-noise）。
そうじゃない論文もある。

一方、私の方法も additive-noise を仮定しますが観測データ x と未観測データ y の線形仮定
しません。

$$v_i = z_i + w_i + n_i, \quad z_i = f^{(i)}(x_j \in P_i, y_k \in Q_k)$$

試行では非線形関数の形は以下の式を仮定

$$y = \tanh(w_3 \tanh(w_2 \tanh(w_1 x + b_1) + b_2) + b_3)$$

※理論上は任意の曲線がフィット出来る。

用分野にはパターン認識やデータマイニング（例：画像認識、レコメンデーション）が挙げられる。学習法は誤差逆伝播法が主流である。

三層以上のニューラルネットワークは可微分で連続な任意関数を近似できることが証明されている（線形分離不可能な問題を解ける）。

形やニューラルネットワークの研究の歴史として生物の神経系の探索であるが、その当初から、それが実際に生物の神経系のシミュレーションで、

<https://ja.wikipedia.org/wiki/%E3%83%8B%E3%83%A5%E3%83%BC%E3%83%A9%E3%83%AB%E3%83%8D%E3%83%83%E3%83%88%E3%83%AF%E3%83%BC%E3%82%AF>